

Bachelorarbeit

KI-Integration in Cloud Native Platform Engineering: Eine systematische Analyse aktueller Lösungsansätze und deren praktische Anwendung

von

Nils Arnold

zur Erlangung des akademischen Grades

Bachelor of Science

im Studiengang Wirtschaftsinformatik

an der Hochschule Konstanz Technik, Wirtschaft und Gestaltung und der Robert Bosch GmbH

Matrikelnummer: 307179

Abgabedatum: 31.01.2026

Erstbetreuer: Prof. Dr. Johannes Schneider

Zweitbetreuer: Lukas Grodmeier.

Abstract

Abstract. . .

Ehrenwörtliche Erklärung

Hiermit erkläre ich, Nils Arnold, geboren am 18. Januar 2003 in Balingen,

(1) dass ich meine Bachelorarbeit mit dem Titel:

„KI-Integration in Cloud Native Platform Engineering: Eine systematische Analyse aktueller Lösungsansätze und deren praktische Anwendung“

bei der Robert Bosch GmbH unter Anleitung von Prof. Dr. Johannes Schneider und Lukas Grodmeier selbstständig und ohne fremde Hilfe angefertigt habe und keine anderen als die angeführten Hilfen benutzt habe;

(2) dass ich die Übernahme wörtlicher Zitate, von Tabellen, Zeichnungen, Bildern und Programmen aus der Literatur oder anderen Quellen (Internet) sowie die Verwendung der Gedanken anderer Autoren an den entsprechenden Stellen innerhalb der Arbeit gekennzeichnet habe.

Ich bin mir bewusst, dass eine falsche Erklärung rechtliche Folgen haben wird.

Ort, Datum

Unterschrift

Inhaltsverzeichnis

Abstract	i
Ehrenwörtliche Erklärung	ii
Inhaltsverzeichnis	iii
1 Einleitung	1
1.1 Problemstellung	1
1.2 Zielsetzung der Arbeit	2
1.3 Aufbau der Arbeit	2
2 Grundlagen und verwandte Arbeiten	3
2.1 Grundlagen	3
2.1.1 Cloud Native Technologien und Platform Engineering	3
2.1.2 DevOps und CI/CD	4
2.1.3 Lernparadigmen des maschinellen Lernens	4
2.1.4 AIOps und verwandte Konzepte	5
2.2 Verwandte Arbeiten	5
3 Methodisches Vorgehen	6
3.1 Vorgehen der Mapping Study	6
3.2 Forschungsfragen	7
3.3 Literatur Analyse Prozess	8
3.3.1 Suchstrategie	8
3.3.2 Auswahlkriterien	8
3.3.3 Schneeballmethode	9
3.3.4 Datenerhebung aus den Studien	9
3.3.5 Datenanalyse und Kategorisierung	10
4 Ergebnisse der Literaturanalyse	11
4.1 Quantitative Analyse	11
4.1.1 Anwendungsbereiche der KI im Platform Engineering	12
4.1.2 Herausforderungen der KI-Integration im Platform Engineering	13
4.1.3 Formen des maschinellen Lernens	14
4.1.4 Verwendete Algorithmen	15

4.2	Ergebnisse der Mapping Study	17
4.2.1	Zusammenspiel der Anwendungsfelder und Herausforderungen . .	17
4.2.2	Zusammenspiel der Lernparadigmen und Algorithmen	19
4.2.3	Zusammenspiel von Herausforderungen und KI-Technologien (Tools und Frameworks)	21
4.2.4	Mapping der zentralen Dimensionen.	22
4.3	Matching/ Framework	25
4.3.1	Überblick und Kategorisierung der KI-Anwendungen	25
5	Anwendung der Literaturrecherche	27
5.1	Bewertungskonzept/ Framework	27
5.2	Analyse der Bosch Digital Manufacturing Plattform	27
6	Diskussion	28
6.1	Beantwortung der Forschungsfragen	28
6.2	Praxisrückschluss	28
6.3	Limitationen.	28
6.4	Handlungsempfehlungen	29
7	Zusammenfassung und Ausblick	30
7.1	Zusammenfassung	30
7.2	Ausblick	30
	Tabellenverzeichnis	31
	Abbildungsverzeichnis	32
	Literaturverzeichnis	33

1

Einleitung

Mit der zunehmenden Verbreitung von Cloud-Native-Technologien und Plattform-Engineering Ansätzen, stehen Unternehmen vor der Herausforderung, ihre Software-Entwicklung und den Plattformbetrieb effizient, skalierbar und resilient zu gestalten. Laut der CNF-Studie geben 89 Prozent der befragten Organisation an, Cloud Native-Technologien zu nutzen [1]. Die Komplexität von Infrastrukturen, Plattformen und Entwicklungsumgebung wächst in diesem Umfeld stark. Diese Entwicklung eröffnet zwar enorme Potentiale für Agilität und Innovation, stellt Plattform-Teams aber gleichermaßen vor neue Herausforderungen. Der Wunsch nach Automatisierung durch den Einsatz von Künstlicher Intelligenz wird immer größer.

1.1. Problemstellung

Trotz der flächendeckenden Verbreitung von Cloud-Native Architekturen und dem klaren Fokus vieler Unternehmen auf Automatisierung und Effizienzsteigerung, bleibt die Frage offen, wie Plattform-Teams konkret von fortgeschrittenen Automatisierungs- und KI-gestützten Ansätzen profitieren. Während zahlreiche Unternehmen bereits erste KI-gestützte Tools in ihren Cloud-Native Umgebungen einsetzen, existiert bislang keine systematische und evidenzbasierte Analyse, welche Lösungen tatsächlich Mehrwert für Plattform-Teams schaffen. Die Forschung zu AIOps und KI im Software-Engineering ist zwar umfangreich, doch deren Bezug zu spezifischen Domänen des Plattform Engineerings wie CI/CD-Automatisierung, Infrastruktur-Management und Monitoring bleibt häufig unscharf. Zudem fehlen praxisnahe Untersuchungen, die auf realen Plattform-

Stacks aufbauen und konkrete Pain Points der beteiligten Teams berücksichtigen. Daraus ergibt sich die Notwendigkeit, den aktuellen Stand der Forschung systematisch zu erfassen, mit industriellen Anforderungen abzugleichen und daraus Handlungsempfehlungen für die Integration von KI in bestehenden Plattformlandschaften abzuleiten.

1.2. Zielsetzung der Arbeit

Ziel dieser Arbeit ist es, eine wissenschaftlich fundierte Grundlage für die Integration von Künstlicher Intelligenz in Cloud-Native-Plattform-Engineering-Umgebung zu schaffen. Hierzu wird zunächst im Rahmen einer systematischen Mapping Study untersucht, welche aktuellen KI-Ansätze im Plattform Engineering existieren und wo genau sie Anwendung finden. Darauf aufbauend erfolgt eine Analyse der Bosch Digital Manufacturing Plattform, um bestehende Herausforderungen zu identifizieren und potenzielle Einsatzfelder von KI-Technologien zu evaluieren. Das Ende der Arbeit setzt sich aus der Entwicklung eines praxistauglichen Frameworks zur Bewertung von KI-Potenzialen in Plattformumgebung sowie mit einer prototypischen Implementierung zusammen. Damit leistet die Arbeit sowohl einen wissenschaftlichen als auch einen praktischen Beitrag zur Weiterentwicklung moderner Plattform-Engineering Praktiken.

1.3. Aufbau der Arbeit

Dieser Abschnitt gibt einen Überblick über den strukturellen Aufbau der Arbeit.

2

Grundlagen und verwandte Arbeiten

In diesem Kapitel werden die theoretischen Grundlagen dargestellt, die für das Verständnis der Arbeit notwendig sind, sowie verwandte Arbeiten eingeordnet.

2.1. Grundlagen

2.1.1. Cloud Native Technologien und Platform Engineering

Cloud Native (CN) gewann ab 2013 insbesondere durch die Etablierung von Containertechnologien bis hin zu Kubernetes an Bedeutung. Im Kern beschreibt CN heute weniger eine einzelne Technologie, sondern ein Zielbild für modular aufgebaute Systeme (z. B. Microservices), die sich gut bereitstellen, skalieren und resilient betreiben lassen. Die CNCF fasst Cloud Native als Ansatz für skalierbare Anwendungen in dynamischen Cloud-Umgebungen zusammen [2].

Kubernetes hat sich dabei als zentrale Plattform etabliert. Es dient als portable, erweiterbare Open-Source-Lösung zur Verwaltung containerisierter Workloads und unterstützt insbesondere deklarative Konfiguration und Automatisierung [3].

Im Platform Engineering werden diese Grundlagen genutzt, um Entwicklerteams über eine interne Plattform (Internal Developer Platform) standardisierte, sichere Self-Service-Capabilities bereitzustellen und damit Lieferfähigkeit, Compliance und Betrieb zu verbessern [4].

2.1.2. DevOps und CI/CD

Development und Operations (DevOps) ist ein kultureller und organisatorischer Ansatz, bei dem Entwicklung und Betrieb gemeinsam Verantwortung für den gesamten Software-Lebenszyklus tragen. Ziel ist es, Zusammenarbeit und Kommunikation zwischen den beteiligten Rollen zu stärken und Abläufe so zu unterstützen, dass Änderungen zuverlässig und kontinuierlich bereitgestellt werden können [5, 6].

Continuous Integration (CI) und Continuous Delivery/Deployment (CD) sind zentrale Praktiken innerhalb von DevOps. CI beschreibt die regelmäßige und automatisierte Integration von Codeänderungen in ein gemeinsames Repository inklusive Build und Tests. CD baut darauf auf und automatisiert die Auslieferung. Continuous Delivery endet vor dem automatischen Produktiv-Deployment, während Continuous Deployment diesen Schritt ebenfalls automatisiert [7, 8].

2.1.3. Lernparadigmen des maschinellen Lernens

Die grundlegenden Lernparadigmen des maschinellen Lernens lassen sich in Supervised Learning (SL), Unsupervised Learning (UL) und Reinforcement Learning (RL) einteilen.

SL trainiert ein Modell anhand gelabelter Daten, sodass es eine Abbildung von Eingaben auf eine Ziel- bzw. Antwortvariable lernt [9, 10].

UL arbeitet mit ungelabelten Daten und zielt darauf ab, darin Strukturen, Cluster oder Auffälligkeiten zu erkennen, ohne dass eine explizite Zielvariable vorgegeben ist [9, 11].

RL beschreibt Verfahren, bei denen ein Agent durch Interaktion mit einer Umgebung Handlungen lernt, um eine langfristige (kumulative) Belohnung zu maximieren [9, 12].

Die drei Lernparadigmen bilden die Grundlage, während die konkrete Umsetzung in der Praxis typischerweise über spezifische Algorithmen und Methoden erfolgt. Tabelle 2.1 fasst die in dieser Arbeit betrachteten Algorithmusklassen zusammen und schafft damit eine einheitliche begriffliche Grundlage für die spätere Auswertung.

Tabelle 2.1: Beschreibung Algorithmen und Methoden

Algorithmen und Methoden	Beschreibung
Deep Learning (DL)/ Neuronale Netze (NN)	Erfassen komplexe Muster in Daten und eignen sich besonders für unstrukturierte Eingaben wie Log- oder Monitoring-Daten.
Ensemble und Baum-basiert	Kombinieren mehrere Modelle zur Steigerung der Vorhersagegenauigkeit und verarbeiten große sowie semi-strukturierte Datensätze effizient.
Klassische Klassifikation/ Regression	Traditionelle ML-Modelle zur Vorhersage von Mustern oder Ereignissen auf Basis strukturierter Daten.
Clustering	Gruppieren Datenpunkte ohne Labels in inhaltlich ähnliche Cluster und unterstützen dadurch Mustererkennung und Anomaliedetektion.

In der Analyse wurden Lernparadigmen zudem auch dann zugeordnet, wenn sie in den Publikationen nicht explizit benannt waren, sondern nur über typische Aufgabenstellungen erkennbar wurden. Solche Aufgabenstellungen werden in den in diesem Abschnitt zitierten Quellen ausführlicher beschrieben.

2.1.4. AIOps und verwandte Konzepte

Definition und Abgrenzung von AIOps, Monitoring, Observability und autonomen Betriebsansätzen.

2.2. Verwandte Arbeiten

Relevante wissenschaftliche Arbeiten, Industriereports und State-of-the-Art-Übersichten werden beschrieben und kritisch eingeordnet.

3

Methodisches Vorgehen

Dieses Kapitel beschreibt das methodische Vorgehen dieser Arbeit. Es erläutert die zugrunde liegende Forschungslogik, die Auswahl des methodischen Ansatzes sowie die Verfahren zur Datenerhebung und -auswertung. Ziel ist es, ein wissenschaftlich fundiertes und zugleich praxisorientiertes Vorgehen aufzuzeigen, das eine systematische Untersuchung der Forschungsfragen ermöglicht. In Abschnitt 3.1 wird eine systematische Mapping Study (SMS) nach Petersen et al [13] angewendet. Abschnitt 3.2 definiert die spezifischen Ziele und konkreten Forschungsfragen dieser Arbeit, welche als Basis für die anschließende Analyse dienen. Darauf aufbauend beschreibt Abschnitt 3.3 den Prozess der Literaturanalyse. Dieser umfasst die Entwicklung einer Suchstrategie, die Definition von Ein- und Ausschlusskriterien, die Schneeballmethode sowie die Schritte der Datenextraktion und -synthese.

3.1. Vorgehen der Mapping Study

Für diese Arbeit wird eine Systematic Mapping Study (SMS) nach den Richtlinien von Petersen, Vakkalanka und Kuzniarz [13] durchgeführt. Diese Methodik dient dazu, den aktuellen Forschungsstand zu einem Themengebiet systematisch zu erfassen, zu kategorisieren und bestehende Forschungslücken zu identifizieren.

Das Vorgehen umfasst die Phasen Planung, Durchführung und Auswertung. In der Planungsphase werden die Forschungsfragen definiert und die Suchstrategie entwickelt, einschließlich der Auswahl relevanter wissenschaftlicher Datenbanken. Dabei wird gezielt nach bestimmten Keywords gesucht, um Publikationen zu finden, die KI-Anwendungen

im Kontext von Platform Engineering adressieren.

Um eine fundierte Datenerhebung und Auswertung sicherzustellen, werden einzelne Prinzipien einer Systematic Literature Review (SLR) nach Kitchenham und Charters [14] berücksichtigt. In der Durchführungsphase werden identifizierte Studien anhand festgelegter Ein- und Ausschlusskriterien geprüft. Zusätzlich wird das Schneeballverfahren nach Wohlin [15] eingesetzt, um die Literatursammlung zu erweitern. Alle Schritte werden dokumentiert, um die Nachvollziehbarkeit und Reproduzierbarkeit sicherzustellen. Die Auswertung erfolgt durch eine systematische Kategorisierung der Studien entlang zentraler Themenfelder des Platform Engineerings. Darauf aufbauend werden Muster, Trends und Forschungslücken identifiziert.

Die Ergebnisse der Mapping Study bilden die Grundlage für die anschließende Analyse der Bosch Digital Manufacturing Platform sowie für die Entwicklung eines Frameworks zur Bewertung von KI-Potenzialen in Cloud-Native Plattformumgebungen.

3.2. Forschungsfragen

Die Forschungsfragen werden durch ein strukturiertes methodisches Vorgehen beantwortet. Jede Forschungsphase ist darauf ausgelegt, das Verständnis über den Einsatz von Künstlicher Intelligenz im Platform Engineering schrittweise zu vertiefen. Die Mapping Study dient der Beantwortung der ersten beiden Forschungsfragen, indem sie eine systematische Übersicht über bestehende KI-Ansätze und deren Anwendungsfelder liefert. Auf Grundlage der Ergebnisse der Mapping Study zielt die dritte Forschungsfrage darauf ab, ein praxisorientiertes Framework zur Beantwortung und Übertragbarkeit von KI-Lösungen zu entwickeln. Die Arbeit ist entlang der folgenden Forschungsfragen strukturiert:

RQ1: Welche typischen Anwendungsfelder (Use Cases) und Herausforderungen bestehen im Platform Engineering, in denen KI-Technologien potenziell Mehrwert bieten können?

Ziel: Systematische Erfassung und Kategorisierung relevanter Use Cases.

RQ2: Welche KI-Technologien (einschließlich Frameworks und Tools) finden derzeit im Platform Engineering Anwendung, und welche Formen des maschinellen Lernens und Algorithmen kommen dabei zum Einsatz?

Ziel: Erstellung einer Übersicht über vorhandene KI-Ansätze und deren typische Einsatzkontexte.

RQ3: Wie lassen sich die identifizierten KI-Lösungen auf typische Anwendungsfälle in Cloud-Native-Platform-Umgebungen übertragen und hinsichtlich ihres Mehrwertes und ihrer Umsetzbarkeit bewerten?

Ziel: Entwicklung eines Bewertungsschemas, das die Passung zwischen KI-Lösungen und spezifischen Platform-Use-Cases beschreibt und die praktische Umsetzbarkeit aufzeigt.

3.3. Literatur Analyse Prozess

Der folgende Abschnitt beschreibt den Ablauf der Literaturanalyse im Rahmen der durchgeführten Mapping Study. Ziel ist es, den methodischen Prozess transparent darzustellen. Dazu werden zunächst die Suchstrategie und die Auswahlkriterien erläutert, gefolgt von der Anwendung der Schneeballmethode. Danach wird die Datenextraktion sowie die Datensynthese beschrieben.

3.3.1. Suchstrategie

Zur Durchführung der Mapping Study wurde eine systematische Suchstrategie angewendet, um relevante wissenschaftliche Publikationen zu identifizieren. Die Literaturrecherche erfolgte in den Datenbanken Google Scholar, SpringerLink, ScienceDirect und IEEE Xplore, da diese eine breite Abdeckung im Bereich Software Engineering, Cloud Native Technologien und KI bieten. Ziel der Suche war, eine möglichst vollständige Übersicht aktueller Forschungsarbeiten zu KI-Anwendungen im Platform Engineering zu erhalten. Dafür wurden gezielt Suchbegriffe und Kombinationen von Suchstrings verwendet, die zentrale Themen der Arbeit abbilden. Die Suchbegriffe waren hierbei: "Platform Engineering", "Cloud-Native", "ÄIOps", "Ärtificial Intelligence", "Machine Learning", "MLOps", "DevOps" und "Kubernetes Cluster".

Zur Transparenz und Vollständigkeit sind die exakten Suchstrings sowie ihre logischen Verknüpfungen im Anhang dokumentiert.

3.3.2. Auswahlkriterien

Um relevante Studien und Publikationen zu identifizieren, wurde ein systematischer Auswahlprozess durchgeführt, der auf klar definierten Ein- und Ausschlusskriterien basiert. Eine Studie wurde in die Analyse aufgenommen, wenn sie alle Einschlusskriterien

erfüllt und zugleich keinem der Ausschlusskriterien unterlag. Die vollständige Übersicht der Kriterien ist in Tabelle 3.1 dargestellt.

Tabelle 3.1: Auswahlkriterien

Kriterium	Beschreibung
EK1	Die Publikation befasst sich mit dem Einsatz von KI oder Machine Learning im Kontext von Platform Engineering, Cloud-Native-Technologien, DevOps oder AIOps.
EK2	Die Studie beschreibt konkrete KI-Methoden, Anwendungen, Architekturen oder Use Cases, die sich auf Plattformumgebungen beziehen.
EK3	Die Arbeit ist wissenschaftlich fundiert, z.B. als Konferenz-, Journal- oder White Paper, auch wenn kein Peer-Review-Verfahren vorliegt.
EK4	Veröffentlichungen sind in englischer oder deutscher Sprache verfasst und nach 2020 erschienen.
AK1	Arbeiten, die keinen direkten Bezug zu KI im Platform Engineering oder verwandten Domänen aufweisen.
AK2	Review-Paper oder systematische Übersichtsarbeiten, die keine eigenen empirischen oder technischen Beiträge enthalten.
AK3	Studien ohne nachvollziehbare methodische Grundlage oder ohne Beschreibung der verwendeten KI-Techniken.

3.3.3. Schneeballmethode

Zur Ergänzung der systematischen Suche wurde eine Schneeballmethode nach den Leitlinien von Wohlin [15] angewendet. Dabei erfolgte sowohl eine Rückwärtssuche als auch eine Vorwärtssuche. Als Ausgangspunkt dienten vier relevante Paper, auf deren Basis zwei Iterationen der Vorwärts- und Rückwärtssuche durchgeführt wurden. Die neu gefundenen Publikationen wurden nach denselben Ein- und Ausschlusskriterien geprüft. Der Prozess wurde beendet, sobald keine weiteren relevanten Studien identifiziert werden konnten.

3.3.4. Datenerhebung aus den Studien

Zur Sicherstellung von Konsistenz und Nachvollziehbarkeit wurde ein strukturierter Prozess zur Datenerhebung aus den Studien umgesetzt. Hierzu wurde eine eigene Extraktionsvorlage entwickelt, die die wesentlichen Merkmale der identifizierten Studien erfasst. Diese Merkmale wurden anschließend entlang von fünf zentralen Dimensionen kategorisiert, wie in Tabelle 3.2 dargestellt.

Tabelle 3.2: Datenextraktion

Dimension	Beschreibung
Forschungskontext	Beschreibt Ziel, Umfang und Art der Studie.
KI-Ansatz und Methode	Erfasst die verwendeten KI- oder ML-Verfahren.
Plattform-Domänen	Ordnet den Beitrag einem Bereich des Platform Engineerings zu.
Ergebnisse und Use-Cases	Fasst die zentralen Erkenntnisse, Anwendungsfälle oder Evaluationsergebnisse zusammen.
Forschungslücke	Dokumentiert identifizierte Limitationen und Ansätze für zukünftige Arbeiten.

Die Extraktion erfolgte qualitativ, wobei relevante Textpassagen und zentrale Aussagen aus jeder Publikation manuell erfasst und den entsprechenden Dimensionen zugeordnet wurden

3.3.5. Datenanalyse und Kategorisierung

Nach der Datenerhebung wurden die Ergebnisse zusammengeführt und ausgewertet, um zentrale Themen, Muster und Forschungslücken zu erkennen. Die ausgewählten Studien wurden nach ihren Inhalten und Schwerpunkten strukturiert und den Forschungsfragen zugeordnet. Zur besseren Übersicht erfolgte die Kategorisierung der Arbeit entlang wichtiger Bereiche des Platform Engineerings. Innerhalb dieser Kategorien wurden die identifizierten KI-Ansätze, Anwendungsfälle und Herausforderungen miteinander verglichen, um wiederkehrende Trends sichtbar zu machen. Die Ergebnisse der Datenanalyse und Kategorisierung werden anschließend in Form einer Mapping Study dargestellt. Diese Übersicht zeigt, in welchen Themenfelder bereits Forschungsschwerpunkte existieren und wo noch Forschungslücken bestehen.

4

Ergebnisse der Literaturanalyse

Dieses Kapitel präsentiert die Ergebnisse der im methodischen Vorgehen beschriebenen Literaturuntersuchung. Zunächst werden in Abschnitt 4.1 die quantitativ erhobenen Merkmale der ausgewählten Publikationen ausgewertet. Abschnitt 4.2 stellt anschließend die Ergebnisse der eigentlichen Mapping Study vor, indem die Arbeiten systematisch klassifiziert und Muster sichtbar gemacht werden. Darauf aufbauend fasst Abschnitt 4.3 die identifizierten KI-Anwendungen im Plattform-Engineering zusammen und leitet ein erstes strukturiertes Matching in Form eines konzeptionellen Frameworks ab. Die dargestellten Ergebnisse bilden die Grundlage für die Beantwortung der Forschungsfragen in Kapitel 6.

4.1. Quantitative Analyse

Zur Einordnung des untersuchten Forschungsfeldes wurden zunächst grundlegende Merkmale der insgesamt 21 Studien analysiert. Abbildung 4.1 a) zeigt die jährliche Verteilung der Publikationen sowie die Zuordnung zu verschiedenen Publikationstypen. Zwischen 2021 und 2023 erscheinen nur wenige Arbeiten (insgesamt fünf), während ab 2024 ein deutlicher Anstieg sichtbar wird. In den Jahren 2024 und 2025 wurden jeweils acht Publikationen identifiziert, überwiegend Journalartikel, ergänzt durch einzelne Konferenzbeiträge, ArXiv-Papers und ein Whitepaper. Dies weist auf ein zunehmendes wissenschaftliches Interesse am Einsatz von KI in Cloud-Native- und Plattform-Engineering-Kontexten hin.

Ergänzend dazu zeigt eine Word Cloud (Abbildung 4.1 b) die am häufigsten vorkom-

menden Keywords aus allen Publikationen. Die Visualisierung bietet einen schnellen Überblick über zentrale thematische Schwerpunkte der Literatur und unterstützt die anschließende inhaltliche Analyse.




Abbildung 4.1: Jährliche und thematische Verteilung der DevOps AI-Forschung

Diese Betrachtung bildet die Grundlage für die folgenden Unterkapitel, in denen die Studien hinsichtlich ihrer inhaltlichen Merkmale detaillierter ausgewertet werden.

4.1.1. Anwendungsbereiche der KI im Platform Engineering

Im ersten Schritt der quantitativen Analyse wurden die insgesamt 21 identifizierten Studien hinsichtlich ihrer Hauptanwendungsbereiche untersucht. Dazu wurden die ausgewählten Bereiche in fünf Kategorien unterteilt: Optimierung von CI/CD-Pipelines, Ressourcen- und Workload-Optimierung, Sicherheits- und Bedrohungserkennung, Resilienz, Self-Healing und Predictive Maintenance sowie Intelligente Bereitstellung (Edge-AI und Serverless Deployment).

Die Auswertung zeigt, dass CI/CD-Automatisierung mit acht Publikationen am häufigsten als primärer Anwendungsbereich beschrieben wird. An zweiter Stelle folgt die Ressourcen- und Workload-Optimierung, die in vier Studien als primärer Anwendungsbereich genannt wird. Ebenfalls wird die intelligente Bereitstellung mittels Edge-AI oder Serverless Deployment in vier Publikationen als zentraler Anwendungsbereich beschrieben. Der vierte Bereich, Resilienz, Self-Healing und Predictive Maintenance wird insgesamt dreimal als Hauptanwendungsbereich definiert. Sicherheits- und Bedrohungserkennung steht in zwei Studien im Mittelpunkt. Abbildung 4.2 zeigt diese Verteilung. Zu beachten ist, dass viele Studien mehr als einen Bereich ansprechen. Für die Vergleichbarkeit wurde jedoch jeweils der dominante Use Case pro Publikation ausgewählt. In der Praxis überschneiden sich die Anwendungsbereiche häufig, da KI-Lösungen oft mehrere Aufgaben gleichzeitig unterstützen.




Abbildung 4.2: Verteilung der Anwendungsbereiche

4.1.2. Herausforderungen der KI-Integration im Platform Engineering

Im nächsten Schritt wurden die in den Publikationen beschriebenen Herausforderungen analysiert, die beim Einsatz von KI im Platform Engineering auftreten. Die analysierten Paper wurden fünf Kategorien zugeordnet. Die Auswertung zeigt, dass 95 % (20/21) der Studien Herausforderungen im Bereich Ressourcenverbrauch und Kosten nennen. Ebenfalls häufig angesprochen werden Skalierbarkeit, Latenz und Monitoring mit 90 % (19/21). AI Governance, Datenschutz und Compliance findet sich in 81 % (17/21) der Arbeiten wieder, ebenso wie die Kategorie Integrationskomplexität und Abhängigkeiten. Die fünfte Kategorie, Datenqualität, Datenverfügbarkeit und Heterogenität, wird in insgesamt 71 % (15/21) der Arbeiten als Herausforderung thematisiert.

Diese Ergebnisse verdeutlichen, dass KI-Anwendungen im Platform Engineering häufig mit mehreren technischen, operativen und organisatorischen Hürden verbunden sind. Viele der Herausforderungen treten zudem gleichzeitig auf, da beispielsweise Skalierungsprobleme oft in engem Zusammenhang mit Ressourcenkosten oder Datenqualität stehen. Die prozentuale Verteilung ist in Abbildung 4.3 dargestellt.




Abbildung 4.3: Relative Häufigkeit der Herausforderungen

4.1.3. Formen des maschinellen Lernens

Ein weiterer Bestandteil der quantitativen Analyse umfasst die in den Publikationen verwendeten Formen bzw. Lernparadigmen des maschinellen Lernens. Dabei wurde unterschieden zwischen (1) explizit benannt, (2) implizit anhand der beschriebenen Methode ableitbar und (3) nur kurz erwähnt ohne weitere methodische Ausführung. Insgesamt wurden die drei grundlegenden Paradigmen identifiziert: Supervised Learning, Unsupervised Learning und Reinforcement Learning.

Die Auswertung zeigt, dass Supervised Learning in den meisten Arbeiten eine zentrale Rolle spielt. Es wird in sechs Publikationen ausdrücklich beschrieben, in elf Arbeiten erkennbar und in zwei kurz erwähnt. Reinforcement Learning wird insgesamt siebenmal explizit genannt und in vier weiteren Arbeiten erwähnt. Unsupervised Learning tritt mit drei expliziten und acht impliziten Nennungen seltener auf, ist jedoch ebenfalls präsent. Die Verteilung ist in der folgenden Abbildung 4.4 dargestellt.




Abbildung 4.4: Formen des maschinellen Lernens

Auffällig ist die deutliche Differenz zwischen explizit und implizit erkennbaren Anwendungen, insbesondere bei Supervised und Unsupervised Learning. Dies zeigt, dass viele Publikationen die entsprechenden Paradigmen beschreiben, ohne die zugrunde liegende Lernform ausdrücklich zu benennen.

4.1.4. Verwendete Algorithmen

Die in den Publikationen verwendeten Algorithmen lassen sich den jeweiligen Lernparadigmen zuordnen. Die Analyse zeigt, dass eine Vielfalt an KI- und ML-Verfahren im Platform-Engineering-Kontext eingesetzt wird. Für eine systematische Bewertung wurde eine eigene Kategorisierung entwickelt. Den Ausgangspunkt bildet die Tabelle aus Enemosah [9], in der verschiedene AI-Techniken für Testfallpriorisierung beschrieben werden. Die Einteilung wurde für den breiteren Kontext dieser Arbeit angepasst.

Auf dieser Basis wurden vier Kategorien definiert, die in Kapitel 2.1 kurz beschrieben sind. Anschließend folgt die quantitative Auswertung der identifizierten Methoden und Algorithmen. Dies zeigt, wie häufig die jeweiligen Verfahren in den Publikationen genannt werden.

Die Ergebnisse zeigen ein deutliches Übergewicht von Deep-Learning-Verfahren, die in insgesamt 86 % (18/21) der Publikationen eingesetzt oder thematisiert werden. Klassische Klassifikations- und Regressionsmethoden treten mit 52 % (11/21) ebenfalls häufig auf. Demgegenüber werden Clustering-Verfahren und Ensemble- bzw. baumbasierte Modelle in 33 % (7/21) der Arbeiten angesprochen. Insgesamt zeigt sich, dass insbesondere neuronale Netze und Deep-Learning-Verfahren die dominierenden Me-

thoden sind.

Diese Verteilung ist in der Abbildung 4.5 dargestellt.




Abbildung 4.5: Verteilung der Algorithmen und angesprochenen Methoden

Die Ergebnisse aus Abschnitt 4.1 zeigen die zentralen Schwerpunkte der betrachteten Studien. Darauf aufbauend wird in Abschnitt 4.2 untersucht, welche Kombinationen zwischen den Kategorien besonders häufig gemeinsam auftreten. Dadurch werden typische Muster innerhalb der Literatur deutlicher sichtbar.

4.2. Ergebnisse der Mapping Study

Um die Beziehungen innerhalb der KI-Forschung im Platform Engineering weiter zu verdeutlichen, baut dieser Abschnitt auf den vorherigen Erkenntnissen auf und präsentiert detaillierte Kreuztabellenanalysen. Diese Zuordnungen untersuchen Beziehungen zwischen Anwendungsfeldern und Herausforderungen (Abschnitt 4.2.1), Lernparadigmen und Algorithmen (Abschnitt 4.2.2), Herausforderungen und KI-Technologien (Abschnitt 4.2.3) sowie Lernparadigmen, Algorithmen und Anwendungsfeldern (Abschnitt 4.2.4). Die Ergebnisse werden als Bubble-Chart-Diagramme visualisiert, in denen die Blasengröße die Häufigkeit der jeweiligen Zuordnung (n) widerspiegelt. Die Häufigkeiten (n) geben an, in wie vielen der betrachteten Studien die jeweilige Zuordnung vorkommt. Pro Studie wird eine Zuordnung je Kombination höchstens einmal gezählt, unabhängig davon, wie häufig sie im Text erwähnt wird. Ziel ist es, durch diese systematischen Mappings tiefere Einblicke in Struktur und Schwerpunkte der aktuellen Forschung zu gewinnen.

4.2.1. Zusammenspiel der Anwendungsfelder und Herausforderungen

Die Abbildung 4.6 zeigt das Zusammenspiel zwischen den identifizierten Use Cases und den zentralen Herausforderungen im Platform Engineering. Im Gegensatz zur Abbildung 4.2 wurden hier alle in den analysierten Studien genannten Anwendungsbe-
reiche berücksichtigt und den jeweils adressierten Herausforderungen zugeordnet. Die Häufigkeiten geben an, wie oft eine bestimmte Kombination in der Literatur thematisiert wurde.




Abbildung 4.6: Korrelation zwischen Anwendungsfeldern (Use Cases) und Herausforderungen

Besonders deutlich wird die starke Verknüpfung der Use Cases Ressourcen- und Workload-Optimierung sowie Resilienz, Self-Healing und Predictive Maintenance mit nahezu allen Herausforderungskategorien. Die Ressourcen- und Workload-Optimierung weist in allen Bereichen hohe Werte auf, je nach Herausforderung liegen diese zwischen $n=13$ und $n=17$. Dieser Anwendungsfall verdeutlicht ein Spannungsfeld zwischen hohem Ressourcenbedarf, Datenmanagement und Pipeline-Komplexität (bedingt durch große und heterogene Datenmengen) sowie Trade-offs zwischen Skalierbarkeit und Latenz, wie es auch in [16] beschrieben wird. Ein ähnlich breites Muster zeigt sich im Bereich Self-Healing und Predictive Maintenance, der über alle Herausforderungskategorien hinweg hohe Häufigkeiten erreicht (zwischen $n=12$ und $n=17$). Insgesamt deutet dies darauf hin, dass beide Use Cases in der Literatur als besonders relevante Einsatzfelder für KI-basierte Optimierungen betrachtet werden, da sie auf zentrale betriebliche Ziele wie Effizienz, Zuverlässigkeit und einen höheren Automatisierungsgrad in DevOps-Prozessen einzahlen [17].

Der Use Case Sicherheits- und Bedrohungserkennung zeigt seine höchste Ausprägung im Bereich AI Governance, Datenschutz und Compliance ($n=14$) sowie bei Ressourcenverbrauch und Kosten ($n=14$). Auch die übrigen Herausforderungen weisen hohe Werte auf ($n=13, 11, 10$). Dies spiegelt wider, dass sicherheitsbezogene KI-Ansätze nicht nur regulatorische und organisatorische Fragen berühren, sondern ebenso Einfluss auf Monitoring, Ressourcenmanagement und Integrationsprozesse haben.

Die CI/CD- und Pipeline-Optimierung zeigt im Vergleich moderate, aber dennoch durch-

gehend hohe Werte über alle Herausforderungen hinweg (n=10, 9, 9, 9, 8). Dies deutet darauf hin, dass KI-Anwendungen zur Optimierung von Build-, Test- und Deployment-Prozessen zwar breit diskutiert werden, aber weniger stark im Zentrum systemübergreifender Herausforderungen stehen als andere Anwendungsbereiche.

Etwas weniger dominant, aber klar erkennbar, ist die Verteilung im Bereich Intelligente Bereitstellung (Edge-AI und Serverless). Die Häufigkeiten liegen zwischen n=14 und n=11 und zeigen damit ein insgesamt konsistentes, jedoch weniger dominantes Muster als in den zuvor genannten Bereichen. Dies legt nahe, dass dieses Anwendungsfeld im aktuellen Forschungsstand zwar relevant ist, jedoch nicht denselben Schwerpunkt bildet wie die großen Themenfelder Optimierung, Resilienz und Sicherheit.

Insgesamt zeigt die Verteilung der Häufigkeiten, dass KI-Anwendungen im Platform Engineering besonders dort adressiert werden, wo Effizienz, Stabilität, Automatisierung und Sicherheitsaspekte zusammenwirken. Die Häufungen bei einzelnen Anwendungsbereichen zeigen, welche Themen in der Forschung besonders im Fokus stehen. Dadurch wird verdeutlicht, in welchen Bereichen KI-Lösungen aktuell als besonders relevant angesehen werden.

4.2.2. Zusammenspiel der Lernparadigmen und Algorithmen

Die Abbildung 4.7 visualisiert die Korrelation zwischen den in den analysierten Studien verwendeten Lernparadigmen des maschinellen Lernens und den eingesetzten Algorithmen. Einige Kombinationen werden in der Darstellung nicht ausgewiesen (n=0 bzw. ohne Blase), da sie in den betrachteten Studien nicht eindeutig als eigenständige Zuordnung berichtet wurden.




Abbildung 4.7: Korrelation zwischen Lernparadigmen und Algorithmen

Supervised Learning weist die größte Bandbreite an möglichen Algorithmen auf. Dies liegt daran, dass überwachte Lernverfahren sowohl tiefen neuronalen Netzen als auch klassischen Klassifikations- und Regressionsmodellen sowie ensemblebasierten Ansätzen zugrunde liegen. Der hohe Anteil an SL-Kombinationen ($n=14$ DL/NN, $n=8$ Klassifikation/Regression, $n=7$ Ensemble/baum-basiert) zeigt, dass SL sehr flexibel einsetzbar ist. Solange gelabelte Daten vorliegen, können verschiedene Algorithmen angewendet werden.

Unsupervised Learning zeigt hingegen ein engeres Spektrum. Die Ergebnisse verdeutlichen, dass UL hauptsächlich in Kombination mit Deep Learning eingesetzt wird ($n=9$) oder mit Clustering-Methoden ($n=6$). Dies ist erwartungsgemäß, da UL in den untersuchten Studien vor allem zur Mustererkennung und Anomalieanalyse eingesetzt wird und Clustering hierbei eine zentrale Rolle einnimmt, wie in [9] beschrieben.

Reinforcement Learning tritt zwar in mehreren Studien auf, wird jedoch selten algorithmisch konkretisiert. RL wird vor allem für dynamische Optimierungsaufgaben eingesetzt. Durch das Lernen auf Basis beobachteter Systemzustände und Feedback können RL-Modelle geeignete Aktionen auswählen. Dadurch können sie zur Stabilisierung des Betriebs und zur Verbesserung der Systemleistung beitragen. Einzelne Arbeiten nutzen hierfür Deep-RL-Ansätze wie Deep Q-Networks [18], insbesondere wenn komplexe Zustandsräume berücksichtigt werden müssen. Insgesamt bleibt die Zuordnung zu spezifischen Algorithmen jedoch begrenzt, weshalb viele Kombinationen in der Tabelle nicht belegt sind.

4.2.3. Zusammenspiel von Herausforderungen und KI-Technologien (Tools und Frameworks)

Im Folgenden wird das Zusammenspiel von Herausforderungen und KI-Technologien (Tools & Frameworks) anhand der Abbildung 4.8 analysiert. Die Werte geben an, in wie vielen Publikationen (n) eine bestimmte Herausforderung gemeinsam mit einer Tool- bzw. Technologiekategorie adressiert wird.




Abbildung 4.8: Korrelation zwischen Herausforderungen und KI-Technologie

Deutlich wird, dass MLOps-Tools & Orchestrierung über alle Herausforderungen hinweg am stärksten vertreten ist (zwischen $n=11$ und $n=14$). Damit zeigt sich, dass MLOps-nahe Technologien in den betrachteten Publikationen besonders häufig im Zusammenhang mit den Herausforderungen adressiert werden.

Für Ressourcenverbrauch und Kosten sowie Skalierbarkeit, Latenz und Monitoring ergeben sich die höchsten Gesamtwerte über alle Tool-Kategorien hinweg. In beiden Fällen treten ML/DL Frameworks & Bibliotheken sowie Monitoring vergleichbar häufig auf (jeweils $n=11$). Das spricht dafür, dass diese Herausforderungen häufig zusammen mit Entwicklungs- und Betriebsaspekten diskutiert werden.

Bei AI Governance, Datenschutz und Compliance zeigt sich ein ähnlicher Schwerpunkt. MLOps-Tools & Orchestrierung werden hier am häufigsten zusammen mit dieser Herausforderung genannt ($n=12$), gefolgt von Monitoring ($n=10$). ML/DL Frameworks & Bibliotheken treten etwas seltener auf ($n=8$). Insgesamt werden Governance- und

Compliance-Themen damit eher auf Betriebs- als nur auf Modell- oder Trainingsebene verortet.

Integrationskomplexität & Abhängigkeiten wird zwar häufig als Herausforderung genannt (vgl. 4.1.2), jedoch seltener explizit mit konkreten Toolkategorien in Verbindung gebracht. Auch hier liegt der Schwerpunkt bei MLOps-Tools & Orchestrierung (n=12) und Monitoring (n=9). ML/DL Frameworks & Bibliotheken (n=8) und Vektordatenbanken (n=4) treten seltener auf. Das verweist darauf, dass Integrations- und Abhängigkeitsfragen vor allem auf System- und Pipeline-Ebene diskutiert werden.

Für Datenqualität, Datenverfügbarkeit und Heterogenität liegen die Werte im Mittelfeld. MLOps wird am häufigsten gemeinsam adressiert (n=11), während ML/DL Frameworks und Monitoring jeweils bei n=9 liegen. Vektordatenbanken sind hier vergleichsweise stärker vertreten (n=6).

Zusammenfassend ist MLOps die am häufigsten vertretene Tool-Kategorie über alle Herausforderungen hinweg. Vektordatenbanken treten insgesamt seltener auf, sind jedoch insbesondere in datenbezogenen Kontexten sichtbar.

4.2.4. Mapping der zentralen Dimensionen

In diesem Abschnitt wird das Zusammenspiel von Lernparadigmen, Algorithmen und den identifizierten Anwendungsfeldern betrachtet. In der Abbildung 4.9 wurden alle Kategorien miteinander dargestellt. Kombinationen ohne Nachweis in den betrachteten Studien werden als n=0 dargestellt (ohne Blase)




Abbildung 4.9: Mapping von Lernparadigmen, Algorithmen und Anwendungsfeldern

Im Supervised Learning dominiert die Kombination aus DL & neuronalen Netzen in allen Anwendungsfeldern. Besonders häufig wird sie bei Ressourcen- und Workload-Optimierung sowie Self-Healing/Predictive Maintenance genannt (jeweils $n=12$), gefolgt von Sicherheits- und Bedrohungserkennung ($n=11$) und Intelligenter Bereitstellung ($n=10$). Auch die Optimierung von CI/CD-Pipelines wird häufig mit DL adressiert ($n=7$). Insgesamt zeigt sich damit, dass Supervised Learning in der betrachteten Literatur vor allem in Verbindung mit DL und neuronalen Netzen eingesetzt wird.

Neben DL werden im Supervised Learning auch Ensemble- und baum-basierte Methoden sowie klassische Klassifikations- und Regressionsverfahren erwähnt, jedoch mit deutlich geringeren Häufigkeiten. Ensemble- und baum-basierte Ansätze liegen je nach Anwendungsfeld zwischen $n=3$ und $n=5$, während klassische Klassifikation/Regression insbesondere bei Ressourcen- und Workload-Optimierung ($n=6$) etwas häufiger vorkommt. Ansonsten sind die Werte ebenfalls geringer und liegen zwischen $n=2$ und $n=5$. Clustering wird im Kontext von Supervised Learning nicht beobachtet, sodass diese Zuordnungen nicht belegt sind ($n=0$).

Für Unsupervised Learning zeigt sich ein anderes Muster. Auch hier wird die Kombination aus DL & neuronalen Netzen über alle Anwendungsfelder hinweg am häufigsten genannt ($n=6-8$). Clustering-Verfahren treten als zweite zentrale Kategorie auf, werden jedoch deutlich seltener thematisiert ($n=3-5$). Insgesamt deutet dies darauf hin, dass Unsupervised Learning hauptsächlich dort eingesetzt wird, wo Abweichungen und Muster ohne gelabelte Daten erkannt werden sollen (z. B. bei Anomalien oder Wartungsvorher-

sagen). Andere Algorithmusklassen (z. B. Ensemble- bzw. klassische Klassifikations-/Regressionsverfahren) sind im Unsupervised-Learning-Kontext nicht belegt ($n=0$), wodurch sich eine klare Fokussierung auf DL/NN und Clustering ergibt.

Im Reinforcement Learning konzentrieren sich die Zuordnungen ausschließlich auf Deep Learning und neuronale Netze. Die Häufigkeiten sind insgesamt geringer als im Supervised- und Unsupervised Learning. Die höchsten Werte zeigen sich bei der Sicherheits- und Bedrohungserkennung ($n=7$) sowie bei der Ressourcen- und Workload-Optimierung ($n=6$). Für die Optimierung von CI/CD-Pipelines und Self-Healing/Predictive Maintenance liegen die Werte jeweils bei $n=5$, während Intelligente Bereitstellung am seltensten genannt wird ($n=4$). Andere Algorithmusklassen sind im RL-Kontext nicht belegt ($n=0$), was die enge Kopplung von RL an DL-basierte (Deep-RL) Ansätze in den betrachteten Publikationen unterstreicht.

Die Kreuztabellenanalysen machen sichtbar, welche Zusammenhänge in der Forschung wiederkehrend sind. Darauf aufbauend wird in Abschnitt 4.3 ein Matching-Framework abgeleitet, das die Ergebnisse strukturiert zusammenfasst. Ziel ist es, daraus eine nachvollziehbare Grundlage für die Bewertung bzw. Einordnung von KI-Ansätzen im Platform Engineering zu schaffen.

4.3. Matching/ Framework

Aufbauend auf den quantitativen Ergebnissen aus Abschnitt 4.1 und den Mustern der Mapping Study in Abschnitt 4.2 wird in diesem Abschnitt ein konzeptionelles Framework abgeleitet. Ziel ist es, die identifizierten KI-Ansätze so zu strukturieren, dass sie auf typische Platform-Use-Cases übertragbar werden. Damit entsteht eine nachvollziehbare Grundlage, um KI-Lösungen später hinsichtlich Mehrwert und Umsetzbarkeit einzuordnen.

4.3.1. Überblick und Kategorisierung der KI-Anwendungen

Tabelle 4.1: Matching-Übersicht

Architekturpattern	Kernkomponenten	Abhängigkeiten	Stärken	Limitationen	Beispielpaper
Erkennung von Abweichungen	Vorhersage-/Prognosemodell (Last, Ausfälle, Verhalten) Prädiktive Analytik, ML-Modelle (Klassifikation, Regression), Historische Daten (Build-Logs, Code-Änderungen).	Qualität/Verfügbarkeit der Trainingsdaten, Geeignete Algorithmusauswahl, Cloud-Native-Architekturen.	Reduziert Build-Fehler/verbessert Pipeline-Effizienz, Intelligente Ressourcenverteilung/Lastoptimierung, Vorhersage von Ausfällen/Deployment-Problemen, Dynamische Anpassung an Traffic-Spitzen.	Umgang mit unstrukturierten Daten ist komplex, Rechenintensiv (bei großen Datensätzen), Risiko des Overfittings (bei Entscheidungsbäumen).	P1, P2, P3, P11, P13, P14, P15, P16, P17, P20, P21
Vorhersage-/Prognosemodell	Entscheidungs- und Optimierungsschleife (dynamische Steuerung) Reinforcement Learning (RL) Algorithmen, Dynamische Ressourcenzuteilung, Autoscaling-Konfigurationen, Feedback-Schleifen.	Genauere Performance-Metriken (Latenz), Definierte Belohnungs-/Strafmechanismen (für RL), Integration in die CI/CD-Pipeline.	Dynamisches Skalieren/-Optimieren der Ressourcennutzung, Minimierung der Betriebskosten, Optimale Verwaltung dynamischer Workloads, Adaptives Deployment.	Komplex in der Implementierung (RL), Erfordert klar definierte Trainingsmechanismen, Hohe Rechenleistung.	P2, P3, P11, P12, P13, P14, P15, P16, P17, P19, P20, P21
Entscheidungs- und Optimierungsschleife	Betriebs-/Integrationspattern für KI, Workflow-Orchestrierung (Kubernetes, Airflow, MLFlow), CI/CD-Komponente, Monitoring (Prometheus, Grafana), Feedback-Schleifen (für Retraining).	Cloud-Native-Prinzipien (Containerisierung, Microservices), DevOps-Automatisierung, Team-Kollaboration (MLOps-Rollen).	Erhöhte Reproduzierbarkeit/Verfolgbarkeit (Data, Code, Model), Kontinuierliches Training/Monitoring, Überwachung der Modell-Performance (Model Drift/Verschlechterung), Steigerung der Zuverlässigkeit/Effizienz von ML-Workflows.	Komplexität der Architektur/Implementierung, Ressourcenintensiv, Benötigt spezialisiertes Fachwissen.	P2, P6, P7, P11, P14, P15, P16, P18, P19, P20, P21
Resilienz, Self-Healing und Predictive Maintenance	Governance-/Compliance-orientierter KI-Betrieb Datenschutz und Sicherheit, Eigentum und Herkunft, Security-Tools (z.B. Snyc, Azure Sentinel), Verschlüsselungsmechanismen, Identitätsmanagement	Einhaltung von Vorschriften, Transparenz und Erklärbarkeit (XAI), Kontinuierliche Sicherheitsüberwachung.	Schutz sensibler Daten, Einhaltung gesetzlicher Anforderungen/Compliance, Vertrauensbildung/Zuverlässigkeit, Reduzierung des Risikos.	Erhöhte Komplexität der Workflows, Interoperabilitätsprobleme (in Multi-Cloud), Schwierigkeiten bei der Erklärbarkeit (XAI) fortgeschrittener Modelle, Hohe Kosten für Compliance.	P3, P4, P9, P11, P12, P14, P15, P16, P17, P18, P19, P20, P21

5

Anwendung der Literaturrecherche

Darstellung des theoretischen Konzepts, seiner Bestandteile und Begründung.

5.1. Bewertungskonzept/ Framework

Hier kommt meine Antwort zu RQ3 hin.

5.2. Analyse der Bosch Digital Manufacturing Plattform

6

Diskussion

Die Ergebnisse werden eingeordnet, Limitationen diskutiert und Implikationen abgeleitet.

6.1. Beantwortung der Forschungsfragen

Zusammenführung der Ergebnisse zur direkten Beantwortung der Forschungsfragen.

6.2. Praxisrückschluss

Übertragbarkeit und Nutzen der Ergebnisse für die Praxis.

6.3. Limitationen

Grenzen der Studie und Ansatzpunkte für Verbesserungen.

6.4. Handlungsempfehlungen

An Bosch gerichtet

7

Zusammenfassung und Ausblick

Abschließende Zusammenfassung der Arbeit sowie ein Ausblick auf zukünftige Forschung.

7.1. Zusammenfassung

Die wichtigsten Erkenntnisse und Ergebnisse der Arbeit werden hier zusammengefasst.

7.2. Ausblick

Mögliche zukünftige Forschungsrichtungen und offene Fragen werden hier diskutiert.

Tabellenverzeichnis

2.1	Beschreibung Algorithmen und Methoden	5
3.1	Auswahlkriterien	9
3.2	Datenextraktion	10
4.1	Matching-Übersicht	26

Abbildungsverzeichnis

4.1	Jährliche und thematische Verteilung der DevOps AI-Forschung	12
4.2	Verteilung der Anwendungsbereiche	13
4.3	Relative Häufigkeit der Herausforderungen	14
4.4	Formen des maschinellen Lernens	15
4.5	Verteilung der Algorithmen und angesprochenen Methoden	16
4.6	Korrelation zwischen Anwendungsfeldern (Use Cases) und Herausforderungen	18
4.7	Korrelation zwischen Lernparadigmen und Algorithmen	20
4.8	Korrelation zwischen Herausforderungen und KI-Technologie	21
4.9	Mapping von Lernparadigmen, Algorithmen und Anwendungsfeldern . . .	23

Literaturverzeichnis

- [1] Rahul Amte. "Cloud-Native AI: Challenges and Innovations in Deploying Large-Scale Machine Learning Models". In: *ISCSITR - INTERNATIONAL JOURNAL OF SCIENTIFIC RESEARCH IN ARTIFICIAL INTELLIGENCE AND MACHINE LEARNING (ISCSITR-IJSRAIML) ISSN (Online): 3067-753X* 6.2 (März 2025), S. 9–18. (Besucht am 05. 11. 2025).
- [2] Adel Zaalouk u. a. "CLOUD NATIVE ARTIFICIAL INTELLIGENCE". In: ().
- [3] Overview. <https://kubernetes.io/docs/concepts/overview/>. (Besucht am 15. 12. 2025).
- [4] juliakm. *What Is Platform Engineering?* <https://learn.microsoft.com/en-us/platform-engineering/what-is-platform-engineering>. (Besucht am 15. 12. 2025).
- [5] *Was ist DevOps? Erläuterung zu DevOps — Microsoft Azure*. <https://azure.microsoft.com/de-de/resources/cloud-computing-dictionary/what-is-devops>. (Besucht am 16. 12. 2025).
- [6] Atlassian. *Was ist DevOps?* <https://www.atlassian.com/de/devops>. (Besucht am 16. 12. 2025).
- [7] *Was ist CI/CD? — Automatisierung in der Softwareentwicklung*. <https://www.redhat.com/de/topics/deis-ci-cd>. (Besucht am 16. 12. 2025).
- [8] Dhia Elhaq Rzig u. a. *Empirical Analysis on CI/CD Pipeline Evolution in Machine Learning Projects*. <https://arxiv.org/abs/2403.12199v4>. März 2024. (Besucht am 16. 12. 2025).
- [9] Aliyu Enemosah. "Enhancing DevOps Efficiency through AI-Driven Predictive Models for Continuous Integration and Deployment Pipelines". In: *International Journal of Research Publication and Reviews* 6.1 (Jan. 2025), S. 871–887. ISSN: 25827421. DOI: [10.55248/gengpi.6.0125.0229](https://doi.org/10.55248/gengpi.6.0125.0229). (Besucht am 03. 11. 2025).
- [10] Dirk Valkenborg u. a. "Supervised Learning". In: *American Journal of Orthodontics and Dentofacial Orthopedics* 164.1 (Juli 2023), S. 146–149. ISSN: 08895406. DOI: [10.1016/j.ajodo.2023.04.010](https://doi.org/10.1016/j.ajodo.2023.04.010). (Besucht am 27. 11. 2025).
- [11] Dirk Valkenborg u. a. "Unsupervised Learning". In: *American Journal of Orthodontics and Dentofacial Orthopedics* 163.6 (Juni 2023), S. 877–882. ISSN: 08895406. DOI: [10.1016/j.ajodo.2023.04.001](https://doi.org/10.1016/j.ajodo.2023.04.001). (Besucht am 27. 11. 2025).
- [12] Majid Ghasemi u. a. *An Introduction to Reinforcement Learning: Fundamental Concepts and Practical Applications*. Aug. 2024. DOI: [10.48550/arXiv.2408.07712](https://doi.org/10.48550/arXiv.2408.07712).

- [13] Kai Petersen, Sairam Vakkalanka und Ludwik Kuzniarz. “Guidelines for Conducting Systematic Mapping Studies in Software Engineering: An Update”. In: *Information and Software Technology* 64 (Aug. 2015), S. 1–18. ISSN: 0950-5849. DOI: [10.1016/j.infsof.2015.03.007](https://doi.org/10.1016/j.infsof.2015.03.007). (Besucht am 06. 11. 2025).
- [14] Barbara Kitchenham und Stuart M. Charters. (PDF) *Guidelines for Performing Systematic Literature Reviews in Software Engineering*. <https://www.researchgate.net/publication/30> (Besucht am 06. 11. 2025).
- [15] Claes Wohlin. “Guidelines for Snowballing in Systematic Literature Studies and a Replication in Software Engineering”. In: *Proceedings of the 18th International Conference on Evaluation and Assessment in Software Engineering*. EASE ’14. New York, NY, USA: Association for Computing Machinery, Mai 2014, S. 1–10. ISBN: 978-1-4503-2476-2. DOI: [10.1145/2601248.2601268](https://doi.org/10.1145/2601248.2601268). (Besucht am 06. 11. 2025).
- [16] Muhammad Talha Tahir Bajwa u. a. “CLOUD-NATIVE ARCHITECTURES FOR LARGE-SCALE AI-BASED PREDICTIVE MODELING”. In: *Journal of Emerging Technology and Digital Transformation* 4.2 (Aug. 2025), S. 207–221. ISSN: 3006-9726. (Besucht am 25. 10. 2025).
- [17] Giridhar Kankanala und Sudheer Amgothu. “AI/ML – DevOps Automation”. In: 13 (Okt. 2024), S. 111–117.
- [18] Josson Paul Kalapparambath, Yugandhar Suthari und Gaurav Mishra. “Advancing Distributed Systems with Reinforcement Learning: A New Frontier in AI-Integrated Software Engineering”. In: (März 2025). ISSN: 2945-3585. DOI: [10.5281/ZENODO.15305618](https://doi.org/10.5281/ZENODO.15305618). (Besucht am 02. 12. 2025).
- [19] Vijay Govindarajan. *Machine Learning Based Approach for Handling Imbalanced Data for Intrusion Detection in the Cloud Environment*. März 2025, S. 815. DOI: [10.1109/ICDT63985.2025.10986614](https://doi.org/10.1109/ICDT63985.2025.10986614).
- [20] Abhishek Gupta und Yashovardhan Chaturvedi. “Cloud-Native ML: Architecting AI Solutions for Cloud-First Infrastructures”. In: *Nanotechnology Perceptions* 20 (Dez. 2024), S. 930–939. DOI: [10.62441/nano-ntp.v20i7.4004](https://doi.org/10.62441/nano-ntp.v20i7.4004).
- [21] Yu Jeffrey Hu, Jeroen Rombouts und Ines Wilms. *MLOps Monitoring at Scale for Digital Platforms*. Apr. 2025. DOI: [10.48550/arXiv.2504.16789](https://doi.org/10.48550/arXiv.2504.16789). arXiv: [2504.16789 \[econ\]](https://arxiv.org/abs/2504.16789). (Besucht am 18. 11. 2025).
- [22] Karthik Puthraya, Rachit Gupta und Beverly DSouza. “The Role of Cloud-Native Architectures in Accelerating Machine Learning Workflows through Data Engineering Innovations”. In: (Feb. 2025). ISSN: 2945-3437. DOI: [10.5281/ZENODO.15106432](https://doi.org/10.5281/ZENODO.15106432). (Besucht am 05. 11. 2025).

- [23] Gopinath Kathiresan. "Cybersecurity Risk Modeling in CI/CD Pipelines Using Reinforcement Learning for Test Optimization". In: *International Journal of Innovative Science and Research Technology* (Mai 2025), S. 15–25. DOI: [10.38124/ijisrt/25may339](https://doi.org/10.38124/ijisrt/25may339). (Besucht am 03. 11. 2025).
- [24] Alexander Keusch u. a. "Platform-Agnostic MLOps on Edge, Fog and Cloud Platforms in Industrial IoT." In: *Proceedings of the 20th International Conference on Web Information Systems and Technologies*. Porto, Portugal: SCITEPRESS - Science and Technology Publications, 2024, S. 71–79. ISBN: 978-989-758-718-4. DOI: [10.5220/0012977500003825](https://doi.org/10.5220/0012977500003825). (Besucht am 18. 11. 2025).
- [25] Dominik Kreuzberger, Niklas Kühn und Sebastian Hirschl. "Machine Learning Operations (MLOps): Overview, Definition, and Architecture". In: *IEEE Access* 11 (2023), S. 31866–31879. ISSN: 2169-3536. DOI: [10.1109/ACCESS.2023.3262138](https://doi.org/10.1109/ACCESS.2023.3262138). (Besucht am 03. 11. 2025).
- [26] Yao Lu u. a. *Computing in the Era of Large Generative Models: From Cloud-Native to AI-Native*. Jan. 2024. DOI: [10.48550/arXiv.2401.12230](https://doi.org/10.48550/arXiv.2401.12230). arXiv: [2401.12230 \[cs\]](https://arxiv.org/abs/2401.12230). (Besucht am 12. 11. 2025).
- [27] *MLOps Approach in the Cloud-Native Data Pipeline Design — Acta Technica Jaurinensis*. <https://acta.sze.hu/index.php/acta/article/view/581>. (Besucht am 04. 11. 2025).
- [28] Swarup Panda. *Scalable Artificial Intelligence Systems: Cloud-Native, Edge-AI, MLOps, and Governance for Real-World Deployment*. Deep Science Publishing, Juli 2025. ISBN: 978-93-7185-753-6.
- [29] Sudip Poudel u. a. "AI-Driven Intelligent Auto-Scaling for Cloud Resource Optimization 1". In: *Journal of Advanced College of Engineering and Management* Vol. 11 (Okt. 2025), S. 27–36. DOI: [10.3126/jacem.v11i1.84521](https://doi.org/10.3126/jacem.v11i1.84521).
- [30] Satheesh Reddy Gopireddy. "Integrating AI into DevOps: Leveraging Machine Learning for Intelligent Automation in Azure". In: *International Journal of Science and Research (IJSR)* 11.6 (Juni 2022), S. 2035–2039. ISSN: 23197064. DOI: [10.21275/SR22619111757](https://doi.org/10.21275/SR22619111757). (Besucht am 03. 11. 2025).
- [31] Vijay Kartik Sikha. "Cloud-Native Application Development for AI- Conducive Architectures." In: *International Journal on Recent and Innovation Trends in Computing and Communication* 11.11 (2023).
- [32] Suprit Pattanayak, Pranav Murthy und Aditya Mehra. "Integrating AI into DevOps Pipelines: Continuous Integration, Continuous Delivery, and Automation in Infrastructural Management: Projections for Future". In: *International Journal of Science and Research Archive* 13.1 (Okt. 2024), S. 2244–2256. ISSN: 25828185. DOI: [10.30574/ijsra.2024.13.1.1838](https://doi.org/10.30574/ijsra.2024.13.1.1838). (Besucht am 03. 11. 2025).

- [33] Venkata Mohit Tamanampudi. "AI-Enhanced Continuous Integration and Continuous Deployment Pipelines: Leveraging Machine Learning Models for Predictive Failure Detection, Automated Rollbacks, and Adaptive Deployment Strategies in Agile Software Development". In: 10 ().
- [34] Varun Tamminedi. "Automating Kubernetes Operations with AI and Machine Learning". In: *IJFMR - International Journal For Multidisciplinary Research* 6.6 (Dez. 2024). ISSN: 2582-2160. DOI: [10.36948/ijfmr.2024.v06i06.33430](https://doi.org/10.36948/ijfmr.2024.v06i06.33430). (Besucht am 03. 11. 2025).
- [35] Sumanth Tatineni. *Integrating Artificial Intelligence with DevOps: Advanced Techniques, Predictive Analytics, and Automation for Real-Time Optimization and Security in Modern Software Development*. Libertatem Media Private Limited, März 2024. ISBN: 978-81-971382-1-8.
- [36] Jeanette Uddoh u. a. "AI-Based Threat Detection Systems for Cloud Infrastructure: Architecture, Challenges, and Opportunities". In: *Journal of Frontiers in Multidisciplinary Research* 2.2 (2021), S. 61–67. ISSN: 30509718, 30509726. DOI: [10.54660/IJFMR.2021.2.2.61-67](https://doi.org/10.54660/IJFMR.2021.2.2.61-67). (Besucht am 04. 11. 2025).